

Rapport de Lab

Data Preparation, segmentation et classification

Diabetes 130-US Hospitals for Years 1999-2008

Prédiction de la réadmission hospitalière à moins de 30 jours

Classe 4CCE13

Noms des membres du groupe : à compléter

4 octobre 2026

1. Business Understanding

Les réadmissions hospitalières précoces chez les patients diabétiques sont coûteuses et révèlent souvent une prise en charge ou un suivi post-sortie insuffisant. Le dataset UCI *Diabetes 130-US Hospitals* regroupe dix ans de données (1999-2008) issues de 130 hôpitaux américains : 101 766 séjours et 50 variables (démographie, diagnostics, examens, médicaments, historique d'hospitalisations).

Problématiques retenues

- **Classification** : prédire si un patient sera réadmis dans les 30 jours suivant sa sortie (`readmitted = <30`). Il s'agit d'un problème binaire (réadmis ou non) avec une classe positive rare (11,4 %).
- **Segmentation** : identifier des profils de patients (complexité du séjour, historique de soins, traitement) et vérifier si certains profils présentent un risque de réadmission plus élevé. La cible n'est pas utilisée pour construire les clusters, seulement pour les interpréter.
- **Objectif méthodologique** : justifier chaque choix de nettoyage et de modélisation, et évaluer les modèles avec des métriques adaptées au déséquilibre (recall, F1, AUC-ROC, AUC-PR).

2. Data Understanding

Le chargement avec `na_values="?"` convertit les valeurs manquantes codées par un point d'interrogation en vraies valeurs manquantes. Les constats principaux :

Constat	Chiffre	Implication
Dimensions	101 766 séjours, 50 colonnes (13 numériques, 37 catégorielles)	Taille suffisante pour la modélisation
Doublons exacts	0	Aucune suppression nécessaire
Patients uniques	71 518 ; 16 773 patients ont plus d'un séjour	Risque de fuite entre train et test : split par patient
Manquants forts	<code>weight</code> 96,9 %, <code>max_glu_serum</code> 94,7 %, <code>A1Cresult</code> 83,3 %, <code>medical_specialty</code> 49,1 %, <code>payer_code</code> 39,6 %	Traitements différenciés (voir section 4)
Manquants faibles	<code>race</code> 2,2 %, <code>diag_3</code> 1,4 %, <code>diag_2</code> 0,35 %, <code>diag_1</code> 0,02 %	Catégorie explicite « Unknown »
Cible	NO 53,9 % ; >30 34,9 % ; <30 11,2 %	Classes déséquilibrées
Colonnes quasi constantes	15 colonnes de médicaments avec plus de 99 % de la même valeur	Aucun pouvoir prédictif : suppression
Décès et hospice	2 423 séjours (<code>discharge_disposition_id</code> 11, 13, 14, 19, 20, 21), dont 96,5 % « NO »	Non réadmissibles : exclusion

Deux pièges de lecture

- Dans `max_glu_serum` et `A1Cresult`, la valeur « None » signifie **test non réalisé**, et non donnée manquante. pandas la lit comme manquante : il faut la recoder, pas l'imputer.
- Les variables `admission_type_id`, `discharge_disposition_id` et `admission_source_id` sont des **codes catégoriels** (décrits dans `IDS_mapping.csv`), pas des quantités.

3. Data Exploration

Variables numériques

- **number_outpatient, number_emergency, number_inpatient** : plus de 90 % de zéros et une queue très longue (maxima 42, 76 et 21). Les boxplots montrent tout le reste comme des outliers.
- **time_in_hospital, num_medications** : asymétrie à droite ; **num_lab_procedures** proche d'une cloche ; **num_procedures** discrète (0 à 6), le « 6 » étant une valeur valide.
- **number_diagnoses** : pic à 9, probablement un plafond de saisie, ce qui limite l'information portée.
- **Corrélations entre variables** : maximum de 0,47 (durée de séjour et nombre de médicaments), donc pas de multicollinéarité grave. **Corrélations avec la cible** : toutes faibles ; la plus forte est number_inpatient (0,17). Le problème est donc intrinsèquement difficile.

Relations avec la réadmission à 30 jours

- **number_inpatient** : le taux passe d'environ 8 % (aucune hospitalisation antérieure) à plus de 30 % (5 et plus). Au-delà de 11, les effectifs sont trop faibles : les barres d'erreur explosent.
- **Âge** : taux de 10 à 12 % pour la plupart des tranches ; pic à 20-30 ans (environ 14 %) mais sur un petit effectif (1 657 séjours).
- **discharge_disposition_id** : très informatif (5 % à plus de 40 %) ; les transferts vers un autre établissement sont les plus à risque.
- **admission_type_id** : peu discriminant (10 à 11 % pour les modalités principales).
- **Traitement** : un ajustement de l'insuline (Up 13 %, Down 13,8 %) ou un changement de traitement (11,8 % contre 10,6 %) sont associés à un risque plus élevé, ce qui est cohérent avec un diabète instable.
- **A1Cresult = None** (test non réalisé) présente le taux le plus élevé (environ 11,4 % contre 9,7 à 10 %) : l'absence de test est elle-même une information.
- **Diagnostics** : plus de 700 codes CIM-9 par colonne ; les plus fréquents sont 428 (insuffisance cardiaque), 414 (cardiopathie ischémique) et 786 (symptômes respiratoires).

4. Data Preparation

Toutes les transformations sont faites sur une copie du dataset. Le tableau ci-dessous résume chaque problème, le traitement choisi et sa justification.

Problème	Traitement	Justification
Décès et hospice (2 423 séjours)	Exclusion	Ces patients ne peuvent pas être réadmis ; les garder gonflerait artificiellement la classe « non réadmis » (96,5 % de NO).
gender = Unknown/Invalid (3 lignes)	Suppression	Effectif négligeable (0,003 %), aucune perte d'information utile.
weight (96,9 % manquant)	Suppression de la colonne	Imputer 97 % de valeurs reviendrait à les inventer.
payer_code (39,6 % manquant)	Suppression de la colonne	Beaucoup de manquants, faible pertinence médicale (assurance du patient), 17 modalités.
15 colonnes de médicaments > 99 % constantes	Suppression	Variance quasi nulle : aucun pouvoir prédictif.
A1Cresult, max_glu_serum : « None »	Recodé en « Not_tested »	Test non réalisé = information médicale. Le taux de réadmission le plus élevé est justement pour « None ».
race, medical_specialty, diag_*	Catégorie « Unknown »	Imputer par le mode fabriquerait de l'information ; supprimer perdrait des milliers de séjours. L'absence est conservée comme modalité.
diag_1/2/3 (716 à 789 codes)	Regroupement en 10 catégories CIM-9	Un one-hot sur 750 codes ferait exploser les dimensions avec des effectifs minuscules.
Codes *_id (admission, sortie)	Regroupement en 3 à 4 modalités	Les codes sont catégoriels ; les modalités rares ou inconnues sont fusionnées selon IDS_mapping.csv.
medical_specialty (72 valeurs)	Top 10 + Unknown + Other	Effectifs supérieurs à 800 pour chaque spécialité retenue.
age (tranches textuelles)	Centre de tranche (5, 15, ... 95)	Variable ordinale : l'ordre est conservé.
Médicaments rares (> 93 % « No »)	Binarisation (prescrit ou non)	Les niveaux Up/Down/Steady ont des effectifs trop faibles.
Outliers (number_*, num_medications, num_lab_procedures)	Winsorisation au 99e percentile	Valeurs médicalement plausibles (patients très hospitalisés = à risque) : on plafonne au lieu de supprimer. Plafonds : 5, 3, 6, 43, 84.
Variables numériques et catégorielles	Scaling et one-hot dans un pipeline, après le split	Évite la fuite d'information du test vers l'entraînement.

Feature engineering

- **n_meds** : nombre de médicaments antidiabétiques prescrits (moyenne 1,17).
- **n_med_changes** : nombre de médicaments dont la dose a été modifiée (75 % des patients : aucun).
- **total_visits** : somme des visites antérieures (consultations externes, urgences, hospitalisations), plafonnée à 10 après winsorisation.

Résultat : 101 766 séjours réduits à 99 340, sans valeur manquante, 37 colonnes dans le fichier exporté (diabetes_clean.csv). La cible binaire readmit_30 compte 11,39 % de positifs. Les identifiants (encounter_id, patient_nbr) et les colonnes de cible (readmitted, readmit_30) ne sont jamais utilisés comme variables explicatives.

5. Segmentation (K-Means)

Choix méthodologiques

- **Variables** : 13 variables numériques et binaires (âge, durée de séjour, analyses, procédures, médicaments, diagnostics, visites antérieures, n_meds, n_med_changes, change, diabetesMed). Les 18 variables textuelles sont exclues : un one-hot massif dilue les distances et rend les clusters illisibles. total_visits est exclue car redondante.
- **StandardScaler** obligatoire : K-Means repose sur des distances, et sans mise à l'échelle num_lab_procedures (0 à 84) écraserait n_med_changes (0 à 4).

Choix de k

k	Inertie	Silhouette
2	1 068 476	0,177
3	982 856	0,135
4	905 226	0,147
5	835 824	0,154
6	784 280	0,161
7	741 392	0,163
8	712 881	0,153

L'inertie décroît régulièrement sans coude net, et les silhouettes sont faibles (0,13 à 0,18) : les patients forment un continuum clinique plutôt que des groupes séparés. k=2 a la meilleure silhouette mais est trop grossier pour définir des profils. Nous avons comparé k=4 et k=5 sur l'interprétabilité : avec k=4, le taux maximal est de 14 % (les patients récurrents sont dilués) ; avec **k=5**, un groupe à haut risque (22 %) est isolé. **k=5 est retenu**.

Profils obtenus (k=5)

Cluster	Effectif	Réadm. <30 j	Profil	Nom proposé
0	4 665 (4,7 %)	22 %	2,4 hospitalisations antérieures, 2,1 urgences, 1,2 consultations externes, 59 ans	Patients récurrents à forte utilisation des soins
1	27 119 (27 %)	11 %	Séjour de 3,7 j, un médicament, aucun changement de dose	Séjours courts, monothérapie stable
2	21 697 (22 %)	9 %	Séjour de 4 j, aucun médicament antidiabétique (diabetesMed = No)	Séjours courts sans traitement antidiabétique
3	14 966 (15 %)	13 %	Séjour de 8,2 j, 26,5 médicaments, 57 analyses, 8,4 diagnostics	Séjours longs et complexes
4	30 893 (31 %)	11 %	Séjour de 3,4 j, environ 2 médicaments, 0,54 changement de dose	Séjours courts, bithérapie avec ajustements

Résultat clé : le cluster 0 regroupe 4,7 % des patients mais présente un taux de réadmission de 22 %, soit 1,9 fois le taux global (11,4 %). Les autres écarts sont modestes (9 à 13 %). La projection ACP en 2D ne sépare pas ce cluster, car il est défini par l'historique de visites, peu représenté sur les deux premiers axes. Les rayures visibles sur le graphe proviennent des variables binaires et discrètes.

Les clusters servent à décrire un profil ; ils ne prédisent pas la réadmission. La prédiction est assurée par le modèle de classification (section 6).

6. Classification

Protocole

- **Cible** : readmit_30 (1 = réadmis en moins de 30 jours).
- **Split par patient** (GroupShuffleSplit sur patient_nbr), car 16 773 patients ont plusieurs séjours : sans cela, le même patient apparaîtrait dans le train et le test. Vérification : 0 patient commun, dans les deux découpages.
- **Deux découpages comparés** : 80/20 et 65/35. Le 65/35 est retenu comme final (test de 34 688 séjours dont 3 969 positifs, donc des métriques plus fiables sur la classe rare).
- **Pipeline** : StandardScaler sur 16 variables numériques, OneHotEncoder sur 17 variables catégorielles, appliqués après le split.
- **Déséquilibre** : le sous-échantillonnage a été écarté (il faudrait supprimer environ 78 % du train pour équilibrer). Méthode retenue : class_weight="balanced", comparée à SMOTE appliqué uniquement sur le train. Le jeu de test garde la distribution réelle.
- **Métriques** : l'accuracy est trompeuse (un modèle répondant toujours « non » aurait environ 89 %). On utilise AUC-ROC, AUC-PR (hasard = 0,114), recall, F1 et matrices de confusion.

Comparaison des modèles

Modèle	Split	AUC-ROC	AUC-PR	Recall	F1
Régression logistique	80/20	0,665	0,203	0,566	0,275
Arbre de décision (profondeur 6)	80/20	0,651	0,199	0,572	0,263
Forêt aléatoire (200 arbres)	80/20	0,668	0,216	0,592	0,273
Régression logistique	65/35	0,660	0,202	0,554	0,270
Arbre de décision	65/35	0,647	0,195	0,614	0,263
Forêt aléatoire	65/35	0,663	0,209	0,576	0,274

Les AUC varient de moins de 0,01 entre les deux découpages et le classement des modèles est identique (forêt > régression logistique > arbre) : les conclusions ne dépendent pas du split. Le recall varie davantage (arbre : 0,572 puis 0,614) car il dépend du seuil de 0,5 ; l'AUC est donc la métrique de comparaison principale. Les écarts entre modèles restent faibles et ont été mesurés sur un seul split.

Comparaison avec SMOTE (forêt aléatoire, split 65/35)

Méthode	AUC-ROC	AUC-PR	Recall	F1
class_weight = balanced	0,663	0,209	0,576	0,274
SMOTE	0,650	0,185	0,103	0,144

SMOTE est moins bon sur les deux AUC, qui ne dépendent pas du seuil : la différence ne s'explique donc pas uniquement par le réglage du seuil. L'effondrement du recall (0,103) montre que les probabilités produites ne sont pas bien placées par rapport au seuil de 0,5. Une explication plausible, non testée ici, est que SMOTE interpole entre points voisins sur des variables one-hot et standardisées, ce qui produit des exemples synthétiques peu réalistes pour les catégories. **class_weight="balanced" est retenu** : plus

simple, sans donnée inventée, et meilleur.

Évaluation détaillée de la forêt aléatoire (test 65/35)

	Prédit non réadmis	Prédit réadmis
Réellement non réadmis (30 719)	environ 20 300	environ 10 400 (fausses alertes)
Réellement réadmis (3 969)	1 681 (manqués)	2 288 (détectés)

Precision 0,18, recall 0,58, F1 0,27 pour la classe « réadmis ». Les patients signalés sont environ 1,6 fois plus à risque que la moyenne ; 82 % des alertes sont de fausses alertes et 42 % des réadmissions sont manquées. Les courbes précision-rappel donnent une AP de 0,19 à 0,21 contre 0,114 pour le hasard : les modèles font environ deux fois mieux que le hasard, ce qui est un gain réel mais modeste. Les valeurs de la matrice sont arrondies car l'affichage scientifique (1e+04) masquait les nombres exacts.

Variables importantes

- **Forêt aléatoire** : number_inpatient (0,21), total_visits (0,155) et discharge_group_Transfer (0,095) dominant, suivis de la durée de séjour, du nombre de médicaments et d'analyses. total_visits contient number_inpatient : l'historique de visites pèse donc au total environ 0,37. Les diagnostics pèsent peu. L'importance d'une forêt favorise les variables continues : à lire comme un ordre de grandeur.
- **Régression logistique** : transfert à la sortie (+0,6), spécialité Nephrology (+0,48), diag_2 Neoplasms, number_inpatient (+0,31, variable standardisée) augmentent le risque. Avec drop="first", chaque coefficient se lit par rapport à la modalité de référence (par exemple Home pour la sortie, ou « Down » pour les médicaments) ; les coefficients négatifs de glipizide ne signifient pas que ce médicament protège.
- Ces résultats décrivent des **associations**, pas des causes.

7. Seuils et niveaux de risque

Avec class_weight="balanced", les probabilités sont gonflées et le seuil de 0,5 est arbitraire. Nous avons plutôt évalué la performance selon la proportion de patients les plus à risque que l'on signale :

% signalés	Seuil	Precision	Recall	Lift
5 %	0,642	0,286	0,125	2,50
10 %	0,610	0,246	0,215	2,15
20 %	0,559	0,212	0,371	1,86
30 %	0,523	0,190	0,497	1,66
40 %	0,489	0,174	0,607	1,52

Il n'existe pas de seuil universel : le choix dépend des ressources de suivi disponibles. Un hôpital qui ne peut suivre que 10 % de ses patients cible un groupe 2,15 fois plus à risque que la moyenne. Pour l'interface, trois niveaux sont définis à partir de ce tableau :

Niveau	Règle (probabilité)	Part des patients	Taux de réadmission estimé
Élevé	$\geq 0,61$	10 %	environ 25 %
Moyen	0,523 à 0,61	20 %	environ 16 %
Faible	$< 0,523$	70 %	environ 8 %

Les taux par niveau sont déduits des lignes à 10 % et 30 % du tableau ; ils seront recalculés exactement dans le notebook final. Les seuils sont fixés sur le jeu de test, ce qui est acceptable dans le cadre d'un lab mais constitue une limite (voir section 8).

8. Conclusion, limites et perspectives

Conclusion

- Le nettoyage a transformé 101 766 séjours bruts en 99 340 séjours exploitables, avec des choix justifiés un par un (décès exclus, tests non réalisés conservés comme information, diagnostics regroupés, outliers plafonnés).
- La segmentation en 5 profils isole un groupe de patients récurrents (4,7 %) dont le taux de réadmission atteint 22 %.
- La classification est modeste mais supérieure au hasard (AUC-ROC environ 0,66, AUC-PR environ 0,21 contre 0,11), stable d'un découpage à l'autre. Le modèle sert à **prioriser** un suivi, pas à décider : sa sortie est un niveau de risque.
- Les facteurs dominants sont l'historique d'hospitalisations, le transfert à la sortie et la durée du séjour.
- **Modèle retenu** : forêt aléatoire avec `class_weight="balanced"` (meilleures AUC, écart faible avec la régression logistique qui reste plus interprétable).

Limites

- Seuils choisis sur le jeu de test ; pas de validation croisée par groupes ; résultats issus d'un seul split par découpage.
- Variables limitées pour la tâche (pas de résultats biologiques détaillés, pas de contexte social) : le plafond de performance est bas, ce qui est cohérent avec les corrélations faibles observées.
- Probabilités non calibrées (effet de `class_weight`) : à présenter en niveaux de risque, pas en pourcentages.
- Données de 1999 à 2008 : les pratiques cliniques ont évolué.
- Associations observées, pas de causalité ; l'outil ne doit pas servir à refuser des soins.

Pistes d'amélioration

- Validation croisée par groupes (GroupKFold) et choix du seuil sur un jeu de validation distinct.
- Gradient boosting et calibration des probabilités.
- Utilisation de l'étiquette de cluster comme variable supplémentaire du classifieur.

Annexe : livrables

Livrable	Contenu
Notebook 1 (exploration et expérimentation)	Sections 1 à 7 : toutes les étapes, comparaisons de modèles, SMOTE, seuils
diabetes_clean.csv	Données nettoyées avant clustering (99 340 lignes, 37 colonnes)
diabetes_clean_clusters.csv	Données nettoyées plus cluster_k4 et cluster_k5
Notebook 2 (modèle final)	Forêt aléatoire, niveaux de risque, sauvegarde des modèles (joblib)
Application Streamlit (app.py)	Formulaire patient, niveau de risque, profil de cluster
Présentation de 10 minutes	Plan en 8 slides